

개요

각자 맡은 데이터 전처리 단계 시도해 보고, 피드백 작성하기

역할 분담

- 김가영: ① 이동: B075. 서울시 내국인 KT 생활이동 데이터
- 안선우: ② 교통: B061. 서울시 버스 30분 단위 이용 통계
- 배우진: ③ 안전: 보안등 위치 / ④ 안전: 서울시(자치구) 연도별 CCTV 설치 현황
- 손주영: ⑤ 환경: 서울시 도로노선 정보

분석 내용

〈안선우〉

- 생성된 격자 수 (bbox 기준) = 124,800
- 최종 데이터프레임 컬럼 수 = 24개

사용된 데이터:

- 버스 30분단위 이용 통계 (샘플 사용함) → 전체 파일 필요
- 서울시 버스정류소 위치정보 (11,237개소)
- 강북구 CCTV 설치 현황 (1개 자치구만 우선 진행)
- 종로구 보안등 현황 (1개 자치구만 우선 진행)

⇒ cctv랑 보안등은 추후 서울시 전체 구 정보 가져와서 전처리 진행해야함

02. 전처리 코딩

Step 1 — 심야버스 정류장 격자 매핑

- v2→v3에서는 공간 좌표 오류 두 건을 수정해 격자와 데이터가 서울 위에 정확히 올라가도록 했고
- v3→v4에서는 실행 환경 독립성을 확보함
- v4→v5에서는 ID 체계 불일치라는 데이터 품질 문제를 정류소명 매핑으로 우회해 실질적인 매핑률을 대폭 끌어올림

v4 → v5 수정 사항:
 [FIX] 좌표 매핑 방식 변경
 - v4: 역ID 기준 매핑 → ID 체계 불일치로 매핑률 10% 미만
 - v5: 정류소명 기준 매핑 → 매핑률 75.9% (전체 데이터 기준)
 - 좌표 파일: 서울시_버스정류소_위치정보.csv (11,237개 정류소)
 - 미매핑 정류장은 출력 후 제외 (전체 데이터 사용 시 해소)

v3 → v4 수정 사항 (유지):
 [FIX] __file__ 기준 경로 자동 설정

v2 → v3 수정 사항 (유지):
 [BUG FIX] 서울시 EPSG:5179 bbox 오류 수정
 - v2: minx=953000 (서울 동쪽 끝보다 동쪽 → 격자가 서울 바깥)
 - v3: minx=934000, maxx=973000, miny=1936000, maxy=1968000 (검증 완료)
 [BUG FIX] 데모 좌표 범위 오류 수정
 - v2: 경도 126.75~127.05 → EPSG:5179 변환 후 격자 밖
 - v3: 경도 126.764~127.183, 위도 37.428~37.702 (서울시 실제 WGS84 범위)

```
===== RESTART: /Users/lucyahn/Documents/데사개 데이터 전처리 02.py =====
=====
서울시 교통공백 분석 | Step 1: 데이터 전처리 v5
=====
[1] 데이터 로드: 전체 500행 | 연도: [np.int64(2017), np.int64(2018), np.int64(2019), np.int64(2020), np.int64(2021)]
    △ 2025년 없음 → 2021년(최신) 사용
    2021년 행 수: 94

[2] 심야 정류장 추출 (기준: [23, 0, 1, 2, 3]시)
    심야 전체 레코드: 4건
    이용 기록 있는 레코드: 4건
    ✓ 심야 운행 고유 정류장: 4개
    STATION_ID    STATION_NM    total_geton    total_getoff
      8992    한빛도서관.명문자동차학원          2          3
      74745    청솔우성아파트.답십리시장          2          0
      8502230    밤골터널          7          3
      9004921    서울스퀘어앞          1          1

[3] 정류장 좌표 조회 (정류소명 기반 매핑)
    △ 좌표 파일 없음: /Users/lucyahn/Documents/서울시_버스정류소_위치정보.csv
    서울 열린데이터 광장에서 다운로드:
    https://data.seoul.go.kr/dataList/0A-15067/5/1/datasetView.do
    → 데모용 임의 좌표로 대체
    ✓ 매핑 성공: 4/4개
    ✓ GeoDataFrame 생성: 4개 (EPSG:5179)
    [정류장] ✓ bbox 내부 | x: 935968~958698, y: 1939375~1963841

[4] 서울시 격자 생성
    △ 행정경계 미지정 → 검증된 bbox 사용
    (934,000, 1,936,000) ~ (973,000, 1,968,000)
    bbox 기준 격자: 124,800개 (경계 클리핑 시 ~60,500개)

[5] 최근접 거리 계산
    격자: 124,800개 | 정류장: 4개
    ✓ 교통 취약 (>500m): 124,490개 (99.8%)
    ✓ 교통 양호 (≤500m): 310개 (0.2%)

[6] 거리 구간별 격자 분포
    dist_band    격자수    비율(%)    취약여부
      0~100m        13        0.0        양호
     100~200m        36        0.0        양호
     200~300m        61        0.0        양호
     300~500m       200        0.2        양호
     500m~1km       947        0.8        취약
      1~2km      3763        3.0        취약
      2km 초과    119780       96.0        취약

[7] 저장 완료 → /Users/lucyahn/Documents/output/
    ├── seoul_grid_transport.geojson (격자 전체)
    ├── seoul_grid_transport.csv (격자 전체)
    ├── night_stops.geojson (심야 정류장)
    └── vuln_grids.geojson (취약 격자)

✓ Step 1 완료. Step 2(보안등·CCTV 매핑)로 진행하세요.
```

Step 2 — CCTV 격자 매핑

<https://data.seoul.go.kr/dataList/OA-11571/S/1/datasetView.do>

```
=====
서울시 교통공백 분석 | Step 2: CCTV 격자 매핑
=====

[1] CCTV 파일 로드
로드: 서울시 강북구 CCTV 설치 현황.csv (2,957행)
→ 전체 합계: 2,957행 (1개 파일)

[2] 데이터 정제
△ 이상치 좌표 제거: 5행 (서울 범위 외)
✓ 정제 후: 2,952행 | 설치 수 합계: 2,952대

[3] 좌표 변환 (WGS84 → EPSG:5179)
✓ EPSG:5179 변환 완료: 2,952개 포인트

[4] 서울시 격자 생성
△ 행정경계 미지정 → 검증된 bbox 사용
bbox 기준 격자: 124,800개

[5] 격자별 CCTV 집계 (공간 조인)
✓ CCTV 있는 격자: 725개 (0.6%)
✓ CCTV 없는 격자: 124,075개 (99.4%)
✓ 격자당 최대 CCTV: 20대
✓ 격자당 평균 CCTV: 0.024대

[6] Step 1 결과 병합 완료
병합 컬럼: ['grid_id', 'nearest_dist_m', 'nearest_stn_id', 'nearest_stn_nm', 'is_transport_vuln']

[7] 복합 취약 격자 (교통+CCTV 모두 취약): 123,803개 (99.2%)

[8] 저장 완료 → /Users/lucyahn/Documents/output/
├── seoul_grid_cctv.csv          (격자 전체)
├── seoul_grid_cctv.geojson     (격자 전체)
└── combined_vuln_grids.geojson (복합 취약 격자)

✓ Step 2 완료. Step 3(보안등 매핑)으로 진행하세요.
```

Step 3 — 보안등 격자 매핑

<https://data.seoul.go.kr/dataList/OA-11567/F/1/datasetView.do>

=====

서울시 교통공백 분석 | Step 3: 보안등 격자 매핑

=====

- [1] 보안등 파일 로드
로드: 서울시 종로구 동별 보안등 현황.csv (9,480행)
→ 전체 합계: 9,480행 (1개 파일)
- [2] 데이터 정제
△ 이상치 좌표 제거: 4행
✓ 정제 후: 9,476행
램프종류 분포: {'LED': 8014, '메탈': 1041, 'CDM': 395, '삼파장': 11, '나트륨': 10, '미상': 3, 'led': 2}
- [3] 좌표 변환 (WGS84 → EPSG:5179)
✓ EPSG:5179 변환 완료: 9,476개 포인트
- [4] 서울시 격자 생성
△ 행정경계 미지정 → 검증된 bbox 사용
bbox 기준 격자: 124,800개
- [5] 격자별 보안등 집계 (공간 조인)
✓ 보안등 있는 격자: 1,125개 (0.9%)
✓ 보안등 없는 격자: 123,675개 (99.1%)
✓ 격자당 최대 보안등: 50개
✓ 격자당 평균 보안등: 0.076개
- [6] Step 2 결과 병합 완료
Step 1 컬럼: nearest_dist_m, is_transport_vuln
Step 2 컬럼: cctv_count, is_cctv_vuln
- [7] 3중 복합 취약 격자 (교통+CCTV+보안등 모두 취약): 122,678개 (98.3%)

단계별 취약 격자 현황:
├ 교통 취약 : 124,490개
├ CCTV 취약 : 124,075개
├ 보안등 취약 : 123,675개
└ 3중 복합 취약 : 122,678개
- [8] 저장 완료 → /Users/lucyahn/Documents/output/
├ seoul_grid_final.csv (Step 1+2+3 최종 통합)
├ seoul_grid_final.geojson (지도 시각화용)
├ triple_vuln_grids.geojson (3중 취약 격자)
└ triple_vuln_grids.csv (3중 취약 격자)

최종 컬럼 구조 (24개):
· grid_id
· centroid_x
· centroid_y
· nearest_dist_m
· nearest_stn_nm
· is_transport_vuln
· cctv_count
· is_cctv_vuln
· cctv_교통단속
· cctv_기타
· cctv_생활방법
· cctv_시설물관리
· cctv_어린이보호
· cctv_재난재해
· light_count
· light_CDM
· light_LED
· light_led
· light_나트륨
· light_메탈
· light_미상
· light_삼파장
· is_light_vuln
· is_triple_vuln

<배우진>

③ 안전: B031. 보안등 위치

전처리 시도1

- [서울시 열린 데이터 광장](#)
- 총 19,316건의 가로등 위치 정보
- 과정 :  서울시_가로등_전처리.ipynb
- 발견된 이슈: 용비교 구간 25건 좌표 오류 (위도=0, 경도=4664046)

문제1

2023년에 데이터가 갱신되어 최신 데이터를 반영할 수 없음.

문제2

이 데이터는 서울특별시 도로사업소와 서울시설공단이 관리하는 가로등의 위치만 담고 있어 서울 가로등의 상당수를 차지하는 25개 자치구 직접 관리 가로등은 포함하지 않음

즉, 서울시 전체 가로등의 일부만 보고 있는 데이터

>> 해결을 위해 공공데이터 포털에서 25개 구의 데이터를 모두 다운로드 하여 다시 전처리 시도를 하였음

전처리 시도2

- [공공데이터포털의 전국보안등정보표준데이터](#)
- 25개 데이터  가로등
- 과정 :  가로등1  가로등2

공공데이터 포털에서 서울시 25개 구의 데이터를 다운로드하여 전처리하였으나 아래와 같은 문제 발생

문제 1 — 모든 지역이 2025년 이후 자료를 가지고 있지 않다는 점

구분	자치구
2025년 이후	관악·성북·서초·강남·광진·강서·강북·영등포·동작·은평·중랑·양천·구로·금천·중구·성동 (16개구)

2023년	종로구·노원구
2021년 이하	강동(2021)·서대문(2020)·도봉(2018)

>> 25개 구 중 4개 구가 2025년 기준 미충족

문제 2 — 마포구·용산구·송파구: 위도·경도가 전부 NaN

파일은 정상적으로 읽히는데 위도·경도 값이 비어있음. 그래서 좌표 필터링 단계에서 전부 제거되어 데이터 최종 결합 파일에 포함될 수 없음

문제 3 — 동대문구: 컬럼 구조 자체가 완전히 다름

위도·경도 컬럼이 아예 없고 번호, 관리번호, 동사무소, 설치일자, 설치주소 형태

좌표 정보가 없어서 격자 분석에 바로 쓰기 어려움

>> [DATA 공공데이터 포털](#) 에서 마포구,용산구,송파구,동대문구 보안등 데이터를 새로 찾아 전처리하려했으나 데이터가 존재하지 않음

④ 안전: 서울시(자치구) 연도별 CCTV 설치 현황

- CCTV 감시 범위 및 밀도
- 서울 열린데이터광장 / 2025년 기준

시트 구성

시트명	설명
자치구별_요약	자치구 × 연도 피벗 + 파생 변수
연도별_자치구	분석/시각화용 Long format
연도별_요약통계	연도별 합계·평균·최대·최솟값

전처리 내용

정제

- '중 구' → '중구' 공백 제거
- '계' 행 분리 (합계 행과 자치구 데이터 분리)

파생 변수 (Long format)

- 누적설치대수 — 자치구별 연도별 누적
- 전년대비증가율(%) — 자치구별 YoY 변화율
- 서울시대비비중(%) — 해당 연도 서울 전체 중 자치구 비중

파생 변수 (Wide format)

- 총계비중(%) — 전체 기간 합산 기준 자치구 점유율
- 연평균설치대수(2017-2025) — 2016년이전 제외한 최근 9개년 평

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	
1	자치구	총계	총계비중(%)	연평균설치대수	2016년이전	2017년	2018년	2019년	2020년	2021년	2022년	2023년	2024년	2025년	
2	종로구	3125	2.55	343	38	55	115	45	223	85	225	1026	1041	272	
3	중구	3427	2.79	337.7	388	366	384	162	352	404	137	138	582	514	
4	용산구	3801	3.1	410.7	105	98	65	317	563	400	446	385	649	773	
5	성동구	4790	3.91	475.9	507	924	454	688	480	361	231	488	368	289	
6	광진구	4872	3.97	534.7	60	652	464	637	194	739	277	348	1015	486	
7	동대문구	4305	3.51	302.1	1586	143	195	211	224	181	234	509	572	450	
8	중랑구	5549	4.53	579.1	337	179	208	1056	987	603	348	689	895	247	
9	성북구	5304	4.33	532.1	515	294	707	632	202	370	337	405	1065	777	
10	강북구	4598	3.75	492	170	1	294	919	533	384	633	370	836	458	
11	도봉구	3114	2.54	345.6	4	22	127	144	151	542	527	643	582	372	
12	노원구	4238	3.46	398.2	654	153	205	315	378	213	161	619	1338	202	
13	은평구	5883	4.8	572.6	730	361	593	1062	441	567	503	462	882	282	
14	서대문구	4305	3.51	313.9	1480	416	246	325	441	327	174	323	511	62	
15	마포구	4050	3.3	331.8	1064	364	346	383	239	164	70	736	473	211	
16	양천구	5066	4.13	517.3	410	557	823	323	349	357	387	994	588	278	
17	강서구	4588	3.74	475.3	310	398	257	454	361	435	604	429	1057	283	
18	구로구	5881	4.8	623.4	270	535	534	784	749	684	336	484	1318	187	
19	금천구	3986	3.25	441	17	109	517	368	511	207	304	824	747	382	
20	영등포구	5450	4.44	437.7	1511	311	657	65	1217	283	346	198	547	315	
21	동작구	4182	3.41	416.4	434	208	300	312	429	31	358	439	1348	323	
22	관악구	7202	5.87	746.9	480	639	662	886	400	550	137	745	1067	1636	
23	서초구	6377	5.2	577.7	1178	1019	416	332	415	565	882	469	744	357	
24	강남구	8600	7.01	762.1	1741	918	726	807	671	501	603	912	610	1111	
25	송파구	5002	4.08	522.1	303	227	516	1052	260	175	373	941	747	408	
26	강동구	4918	4.01	443.4	927	273	377	356	614	262	381	359	688	681	
27															

주요 수치

- 서울 전체: 122,613대 (25개 자치구)
- 최다 자치구: 강남구 8,600대 (7.01%)
- 설치 급증 연도: 2024년 20,270대 (최고치)
- 관악구가 2025년 단독 1,636대로 올해 최다 설치

<손주영>

사용 데이터: B030 서울시 도로노선 정보

v1 → v2 수정사항:

[FIX] pandas Copy-on-Write 경고 수정

- df['도로폭_수치'].fillna(..., inplace=True)

→ df['도로폭_수치'] = df['도로폭_수치'].fillna(...) 로 변경

파이썬 전처리 과정 사진 첨부

```
C:\Users\82102\OneDrive\바탕 화면\새 폴더 (2)>python 도로노선_전처리.py
[로딩 완료] 총 14,073행, 7개 컬럼
[결측값 처리] '불가' 53건 → 최빈값 3.0m 으로 대체
[결측값 처리 후] 잔여 결측값: 0건

=== 전처리 완료 요약 ===
총 행 수: 14,073
결측값 현황:
순번      0
노선명     0
도로종류   0
도로기능   0
도로규모   0
도로폭_원본 0
도로폭_수치 0
작업일시   0
dtype: int64

도로폭_수치 기술통계:
count    14073.00
mean      5.47
std       5.20
min       3.00
25%       3.00
50%       3.00
75%       7.00
max       60.00
Name: 도로폭_수치, dtype: float64

☑ 저장 완료: 서울시_도로노선_정보_전처리완료.csv
C:\Users\82102\OneDrive\바탕 화면\새 폴더 (2)>
```

전처리 완료 파일 [서울시 도로노선 정보 전처리완료.csv](#)

전처리 결과:

- 총 행 수: 14,073행

- 전체 결측값: 0건
- '불가' 53건 → 최빈값 3.0m 으로 대체
- 도로폭_수치 기술통계:
 - 평균: 5.47m
 - 최솟값: 3.0m
 - 최댓값: 60.0m
 - 중앙값(50%): 3.0m

〈김가영〉

사용된 데이터

- 수도권 생활이동 (도착 행정동 기준 시간대별 성연령별 수단 데이터 (내국인)): 2025년 1월~12월 <https://data.seoul.go.kr/dataList/OA-22655/F/1/datasetView.do#>
 - → 전처리 대상 데이터
- 행정구역 법정동 경계: <https://data.seoul.go.kr/bsp/wgs/dataView/data300View/10080.do>
 - 수도권 생활이동 데이터의 분류가 행정구 단위로 되어 있으므로, 분석을 위해 함께 사용.

- 사용 코드(데이터를 부분으로 나누어

```
Users > k727 > ≡ 심야이동_데이터 전처리_1번 ●
1 import pandas as pd
2 import numpy as np
3
4 # 1. 파일 목록 (Verbatim Reference)
5 file_list = [
6     "seoul_trans_admdong1_in_20250101.csv", "seoul_trans_admdong1_in_20250102.csv",
7     "seoul_trans_admdong1_in_20250103.csv", "seoul_trans_admdong1_in_20250104.csv",
8     "seoul_trans_admdong1_in_20250105.csv", "seoul_trans_admdong1_in_20250106.csv",
9     "seoul_trans_admdong1_in_20250107.csv", "seoul_trans_admdong1_in_20250108.csv",
10    "seoul_trans_admdong1_in_20250109.csv", "seoul_trans_admdong1_in_20250110.csv"
11 ]
12
13 # 2. 데이터 통합
14 all_data = pd.concat([pd.read_csv(f) for f in file_list], ignore_index=True)
15
16 def calculate_smi(df):
17     """
18     분석 계획서에 정의된 SMI 지수를 산출하는 함수
19     SMI = ((주간 평균 - 심야 평균) / 주간 평균) * 100
20     """
21     # 주간 시간대 (예: 08시 ~ 20시) 및 심야 시간대 (00시 ~ 04시) 정의
22     # 데이터의 time_cd 기준 (0~23)
23     daytime_hours = list(range(8, 21))
24     nighttime_hours = [0, 1, 2, 3, 4]
25
26     # 시간대별 평균 이동량 계산 (행정동별)
27     day_avg = df[df['time_cd'].isin(daytime_hours)].groupby('d_admdong_cd')['total_cnt'].mean()
28     night_avg = df[df['time_cd'].isin(nighttime_hours)].groupby('d_admdong_cd')['total_cnt'].mean()
29
30     # SMI 계산
31     smi_df = pd.DataFrame({'day_avg': day_avg, 'night_avg': night_avg})
32     smi_df['SMI'] = ((smi_df['day_avg'] - smi_df['night_avg']) / smi_df['day_avg']) * 100
33
34     return smi_df.reset_index()
35
36 # 3. 지표 산출 실행
37 smi_results = calculate_smi(all_data)
38
39 # 4. 결과 확인 및 필터링 (계획서 기준 상위 20% 추출)
40 threshold = smi_results['SMI'].quantile(0.8)
41 vulnerable_areas = smi_results[smi_results['SMI'] >= threshold]
42
43 print(f"이동 취약 구역(SMI 상위 20%) 기준치: {threshold:.2f}%")
44 print(vulnerable_areas.sort_values(by='SMI', ascending=False).head())
45
46 # (추후 과정) 이 결과를 격자 데이터(100m) 및 인프라 데이터와 Join하여 시각화 수행
```

- 피드백

1. 데이터 용량 및 메모리 점유 문제

- 문제 상황: 1년치(1월~12월) 서울시 생활이동 데이터의 볼륨이 큼. 이를 한꺼번에 한달치 정도 분석할 경우 시스템이 멈추거나 분석 속도가 현저히 저하되었음

2. 반복적인 파일 로드 및 관리의 비효율성

- 문제 상황: 파일이 일별로 쪼개져 있어 코드에 파일명을 수동으로 입력해야 하며, 파일 누락이나 오타로 인한 분석 오류가 반복적으로 발생하였음.
- 해결책: 해결책: glob 라이브러리를 활용한 파일 로딩 자동화를 구축함. / 파일명의 패턴(예: seoul_trans_*.csv)을 인식하여 폴더 내의 모든 파일을 자동으로 리스트업하는 코드를 작성했음.

```
import glob
# 'seoul_trans_*.csv' 패턴에 맞는 모든 파일을 한 번에 가져옴
file_list = sorted(glob.glob("./data/seoul_trans_admdong1_in_*.csv"))
```